NeuroAssist AI: Uma Plataforma Offline-First e Preservadora de Privacidade para Comunicação Assistiva Baseada em Gestos Faciais Residuais em Doenças Neurodegenerativas

Danilo Amaral[1]

[1]TechLab AI
cybernautta@gmail.com

Resumo. *Pacientes com doença do neurônio motor (DNM/ELA) perdem progressivamente o controle motor voluntário, frequentemente retendo apenas movimentos faciais sutis como último canal de comunicação. Os sistemas de comunicação aumentativa e alternativa (CAA) existentes requerem conectividade de rede estável e não se adaptam ao perfil motor residual individual do paciente. Apresentamos o NeuroAssist AI, uma plataforma de comunicação assistiva offline-first e preservadora de privacidade que transforma gestos faciais residuais em solicitações de emergência estruturadas, utilizando um pipeline de visão computacional baseado em WebAssembly executado localmente. O sistema combina uma máquina de estados de seis estados para reconhecimento de gesto deliberado com calibração de limiar EAR específica por paciente, implantado sobre uma arquitetura de microsserviços hexagonal. Avaliamos o sistema com um paciente DNM em estágio avançado e cinco cuidadores e voluntários em um estudo de caso preliminar. A latência ponta-a-ponta da conclusão do gesto até a exibição do alarme ao cuidador foi em média* ***[X]*** *ms (σ = [Y] ms) em [N] tentativas. A máquina de estados de gesto deliberado reduziu a taxa de falsos positivos de [A] % (limiar EAR simples) para [B] % ([N] participantes). O NeuroAssist AI demonstra que a detecção precisa e preservadora de privacidade de gestos residuais é alcançável em hardware comum sem dependência de rede, usando uma arquitetura calibrável e extensível validada em contexto real de cuidado domiciliar de DNM.*

Abstract. *Patients with motor neurone disease (MND/ALS) progressively lose voluntary motor control, often retaining only subtle facial movements as their last communication channel. Existing augmentative and alternative communication (AAC) systems require reliable network connectivity and do not adapt to the residual motor profile of individual patients. We present NeuroAssist AI, a privacy-preserving, offline-first assistive communication platform that transforms residual facial gestures into structured emergency requests using a locally executed WebAssembly-based computer vision pipeline. The system combines a six-state deliberate gesture recognition state machine with patient-specific EAR threshold calibration, deployed over a hexagonal microservices architecture. End-to-end latency averaged [X] ms (σ = [Y]) across [N] trials. The state machine reduced the false-positive rate from [A] % to [B] %. NeuroAssist AI demonstrates that high-accuracy, privacy-preserving residual gesture detection is achievable on commodity hardware without network dependency.*

1. Introdução

A esclerose lateral amiotrófica (ELA), internacionalmente denominada motor neurone disease (MND) ou amyotrophic lateral sclerosis (ALS), é uma condição neurodegenerativa progressiva que destrói os neurônios motores superiores e inferiores, resultando em perda de movimento voluntário, fala e, por fim, função respiratória. A incidência global é de aproximadamente 2–3 casos por 100.000 pessoas-ano, afetando cerca de 41.000 indivíduos na Austrália e 30.000 no Brasil [Mehta et al. 2018]. A sobrevida mediana após o diagnóstico é de 2–5 anos; a insuficiência respiratória, tipicamente tratada com ventilação não invasiva (VNI), é a principal causa de morte. Notavelmente, a VNI demonstrou prolongar a sobrevida por um fator de aproximadamente três em comparação ao melhor tratamento farmacológico disponível [Berlowitz and Sheers 2021], tornando o período de uso da VNI clinicamente significativo e prolongado. Durante essa fase, os pacientes permanecem cognitivamente intactos enquanto se tornam progressivamente incapazes de falar ou gesticular de formas que as tecnologias de comunicação padrão consigam detectar.

Trabalhos recentes demonstraram que a assincronia paciente-ventilador (PVA) — uma incompatibilidade entre os ciclos do ventilador e o esforço respiratório do paciente — é um contribuinte significativo para a não adesão à VNI na ELA, causando desconforto, fragmentação do sono e potencialmente desfechos clínicos adversos [Atkeson et al. 2011, Yang et al. 2026, Berlowitz et al. 2025]. Pacientes que experimentam desconforto relacionado à PVA durante o uso noturno da VNI não conseguem sinalizar angústia facilmente aos cuidadores usando as tecnologias de CAA existentes, que requerem conectividade de rede ou hardware dedicado inadequado para o ambiente domiciliar. O NeuroAssist AI aborda diretamente essa lacuna: ao fornecer um canal de sinalização local e sempre disponível que requer apenas uma webcam comum, permite que os pacientes alertem os cuidadores durante períodos sem supervisão — incluindo enquanto utilizam a VNI à noite.

Em estágios avançados, uma proporção substancial de pacientes experimenta uma condição semelhante ao locked-in, na qual o controle voluntário se limita a movimentos faciais residuais sutis: pequenas contrações palpebrais, elevações de sobrancelha ou microexpressões que persistem após a perda da função motora dos membros e orofacial. Esses gestos residuais representam o último canal voluntário disponível para comunicação. Sem um meio confiável de detectá-los e agir sobre eles, os pacientes não conseguem sinalizar angústia, desconforto ou necessidades aos cuidadores — com consequências diretas para a qualidade de vida e a segurança do paciente durante períodos sem assistência.

Os sistemas de comunicação aumentativa e alternativa (CAA) existentes não atendem adequadamente essa população. Dispositivos de rastreamento ocular de ponta (e.g., Tobii Dynavox) e softwares de CAA dedicados (e.g., Grid 3) oferecem alta precisão, mas requerem conectividade sem fio estável, hardware dedicado custando mais de USD 3.000, e configurações calibradas em fábrica que não conseguem se adaptar ao perfil motor em declínio de um paciente individual [Beukelman and Mirenda 2013]. Interfaces cérebro-computador (BCI) via EEG oferecem uma alternativa, mas envolvem hardware invasivo ou volumoso inadequado para implantação domiciliar [Zander and Kothe 2011]. Abordagens baseadas em câmera de baixo custo existem na literatura [Soukupová and Čech 2016], mas dependem de comparações simples de limiar por quadro que geram taxas de falsos positivos inaceitavelmente altas quando aplicadas à atividade facial involuntária presente

em pacientes com ELA durante a VNI.

Apresentamos o **NeuroAssist AI**, uma plataforma de comunicação assistiva offline-first e preservadora de privacidade projetada para implantação domiciliar com uma webcam comum. O sistema transforma gestos faciais residuais em solicitações de emergência estruturadas usando um pipeline de visão computacional WebAssembly executado localmente, uma máquina de estados de gesto deliberado e um perfil de detecção calibrável por paciente — sem transmitir nenhum vídeo para fora do dispositivo.

Este artigo apresenta três contribuições originais:

1. **Um pipeline de detecção offline-first e preservador de privacidade.** O modelo MediaPipe FaceLandmarker e seu runtime WebAssembly são servidos a partir de ativos locais; nenhum quadro de vídeo ou dado biométrico sai do dispositivo do paciente. O delegate de CPU garante compatibilidade com hardware comum, independentemente da disponibilidade de GPU.
2. **Uma máquina de estados de gesto deliberado de seis estados com calibração específica por paciente.** Em vez de um único limiar EAR, a máquina de estados exige duração mínima de fechamento ($\geq$3 quadros, $\approx$100 ms) em cada uma de duas piscadas sequenciais, reabertura confirmada entre elas, e uma janela de tempo configurável. Os limiares são armazenados em um `DetectionProfile` versionado e adaptados por paciente. Esse design aborda especificamente as fontes de falsos positivos relevantes para a ELA: piscadas involuntárias, artefatos de ptose parcial e deriva lenta de limiar.
3. **Uma arquitetura extensível de microsserviços hexagonais com tipos de gesto plug-in.** O campo `engineFeatureRef` no perfil de detecção desacopla o motor de reconhecimento de gesto do catálogo de comandos, permitindo que novos gestos (elevação de sobrancelha, piscada de um olho) sejam registrados sem modificar o código de domínio existente. Regras ArchUnit aplicadas em tempo de compilação garantem que essa separação persista à medida que o sistema evolui.

O restante do artigo está organizado da seguinte forma. A Seção 2 revisa os trabalhos relacionados em CAA, detecção de gesto facial e computação de borda para saúde. A Seção 3 descreve a arquitetura do sistema em detalhe. A Seção 4 relata a avaliação experimental. A Seção 5 discute limitações e trabalhos futuros, e a Seção 6 conclui o artigo.

2. Trabalhos Relacionados

2.1. Sistemas de CAA para Doenças Neurodegenerativas

A comunicação aumentativa e alternativa (CAA) para pessoas com ELA tem sido estudada extensivamente desde a década de 1990 [Beukelman and Mirenda 2013]. Soluções comerciais dominam a prática clínica: dispositivos de rastreamento ocular de ponta, como o Tobii Dynavox PCEye e o Eyegaze Edge, oferecem seleção por olhar com precisão superior a 98 % em condições laboratoriais, mas apresentam custos de hardware acima de USD 3.000 e requerem recalibração periódica por profissionais treinados [Beukelman and Mirenda 2013]. Esses sistemas pressupõem controle oculomotor residual suficiente, que se deteriora à medida que a ELA progride em direção à oftalmoplegia. Pacotes de software de CAA como o Grid 3 dependem de conectividade Bluetooth

ou Wi-Fi estável para sincronizar conjuntos de símbolos e perfis de usuário, criando uma barreira para usuários domiciliares sem banda larga confiável.

Uma pesquisa de Clarke et al. [Clarke et al. 2021] identificou que a provisão de CAA para pessoas com ELA é caracterizada por encaminhamento tardio, transições rápidas de dispositivos à medida que a função motora declina, e uma lacuna persistente em soluções de baixo custo e adaptáveis adequadas para o ambiente domiciliar. As interfaces cérebro-computador (BCI) via eletroencefalografia oferecem um caminho alternativo que contorna o sistema motor por completo, mas os headsets de BCI não invasivos atuais atingem taxas típicas de transferência de informação de 5–25 bits por minuto em condições ótimas, requerem operadores treinados e são inadequados para o contexto de cuidado domiciliar [Zander and Kothe 2011]. BCIs corticais implantadas atingem taxas maiores, mas apresentam risco cirúrgico. O NeuroAssist AI visa o estágio intermediário — após a perda da função dos membros e da fala, mas enquanto persiste algum grau de movimento facial voluntário — para o qual não existe atualmente nenhuma solução de baixo custo e independente de rede na literatura.

2.2. Detecção de Gesto Facial via Visão Computacional

Três gerações de análise facial baseada em câmera são relevantes para este trabalho.

Primeira geração — classificadores em cascata. Viola e Jones [Viola and Jones 2004] introduziram a detecção de faces em tempo real usando cascatas de características Haar, permitindo a implantação em hardware de consumo. Esses detectores localizam o rosto, mas não fornecem coordenadas de marcos sub-faciais; a detecção de piscadas requer heurísticas adicionais aplicadas à região do olho detectada e é altamente sensível a variações de iluminação.

Segunda geração — regressão de marcos faciais. A biblioteca Dlib de King [King 2009] popularizou a detecção de 68 marcos faciais por meio de um conjunto de árvores de regressão, permitindo o cálculo confiável do EAR [Soukupová and Čech 2016] sem aprendizado profundo. Soukupová e Čech [Soukupová and Čech 2016] formalizaram o EAR como um escalar único para detecção de piscadas, demonstrando precisão de detecção em nível de quadro acima de 99 % em conjuntos de dados controlados. A principal limitação dessa geração é a ausência de um runtime compatível com WebAssembly, tornando a implantação no navegador do lado do cliente impraticável.

Terceira geração — modelos de marcos profundos no dispositivo. O MediaPipe FaceLandmarker [Lugaresi et al. 2019] fornece 468 marcos faciais normalizados e 52 coeficientes de blendshape a aproximadamente 30 fps em um contexto de navegador WebAssembly usando apenas um delegate de CPU. O NeuroAssist AI se baseia nessa geração, retendo o EAR para a máquina de estados de dupla piscada (onde sua simplicidade auxilia a interpretabilidade) enquanto usa pontuações de blendshape para gestos de piscada de um olho e sobrancelha.

2.3. Reconhecimento de Gesto Deliberado e Supressão de Falsos Positivos

Um desafio fundamental em CAA acionada por gesto é distinguir ativações intencionais da atividade facial involuntária que ocorre continuamente durante o comportamento normal. A taxa de piscadas espontâneas em adultos saudáveis é de 15–20 piscadas por minuto [Bentivoglio et al. 1997]; em pacientes com ELA, as taxas podem ser menores

devido à perda de neurônios motores, mas permanecem diferentes de zero. Qualquer abordagem baseada em limiar aplicada no nível de quadro único produz taxas de falsos positivos da ordem de vários por minuto em condições naturais, tornando o monitoramento sem supervisão inviável.

As duas principais estratégias na literatura para suprimir falsos positivos em CAA facial são *tempo de permanência* (*dwell time*) e *modelagem de intencionalidade*. A seleção por tempo de permanência — amplamente usada em CAA baseada em olhar — exige que o usuário fixe uma região-alvo por uma duração fixa (tipicamente 0,5–1 s) [Majaranta and Räihä 2002]. Essa abordagem é inaplicável à entrada baseada em piscada, pois uma piscada por definição fecha o olho e interrompe a fixação. A modelagem de intencionalidade via máquinas de estados foi proposta na literatura mais ampla de interação humano-computador [Zander and Kothe 2011], mas sua aplicação à CAA baseada em piscada para ELA não foi sistematicamente descrita. A máquina de seis estados introduzida neste artigo (Seção 3.3) aplica restrições de intencionalidade específicas ao gesto de dupla piscada: duração mínima de fechamento por piscada, abertura confirmada entre piscadas, e uma janela temporal — combinação não encontrada, ao conhecimento dos autores, na literatura anterior de CAA.

2.4. Computação de Borda e Privacidade para Aplicações de Saúde

O processamento de dados de sensores relacionados à saúde no dispositivo, em vez de na nuvem, tem recebido atenção crescente após a aplicação do GDPR em 2018 e da LGPD em 2020 [European Data Protection Board 2020]. O vídeo facial é classificado explicitamente como dado biométrico sob ambos os marcos regulatórios, atraindo as maiores obrigações regulatórias de processamento. A execução local via WebAssembly fornece uma garantia prática de privacidade: o modelo de execução com memória isolada da especificação impede que um módulo carregado acesse qualquer estado do navegador fora de sua memória linear, e nenhuma chamada de rede é necessária para executar a inferência do marcador de landmark [Haas et al. 2017]. A latência de implantação de modelos WebAssembly para análise facial foi relatada em 20–40 ms por quadro em hardware de consumo sem aceleração por GPU [Lugaresi et al. 2019], consistente com a operação a 30 fps observada em nosso PoC.

2.5. Arquitetura de Software para Sistemas de Saúde

A arquitetura Hexagonal (Portas e Adaptadores) [Cockburn 2005] foi proposta como um padrão estrutural para sistemas de informação em saúde onde o modelo de domínio deve permanecer isolado de mudanças tecnológicas — um requisito recorrente em software de saúde regulamentado onde requisitos de auditoria, esquemas de dados e padrões de integração evoluem de forma independente [Richardson 2018]. A decomposição em microsserviços de plataformas de CAA não foi relatada na literatura, ao conhecimento dos autores; a maioria dos sistemas existentes são aplicações monolíticas de desktop ou firmware. A arquitetura do NeuroAssist AI demonstra que decompor um pipeline de gesto-para-alarme em serviços independentemente implantáveis é viável em escala de PoC, e que a aplicação de limites em tempo de compilação via ArchUnit fornece um mecanismo prático para manter a disciplina hexagonal.

2.6. Comunicação e Segurança Durante o Uso de VNI na ELA

A adesão à ventilação não invasiva na ELA está consistentemente abaixo das metas clínicas, com desconforto relatado pelo paciente e assincronia dispositivo-paciente identificados como principais fatores contribuintes [Berlowitz and Sheers 2021, Yang et al. 2026]. A polissonografia domiciliar em 23 pacientes com ELA utilizando VNI noturna documentou um índice de assincronia médio de 69 eventos por hora (intervalo 15–146) — muito acima dos limiares associados à perturbação clinicamente significativa do sono [Atkeson et al. 2011]. O ensaio clínico randomizado 3TLA [Berlowitz et al. 2025] investiga atualmente se a titulação da VNI guiada por polissonografia melhora as taxas de uso; seu desfecho primário — uso de VNI superior a quatro horas por dia — reflete o desafio de manter a adesão em ambientes domiciliares. Uma dimensão complementar e pouco explorada é a capacidade do paciente de sinalizar desconforto ou angústia aos cuidadores durante o uso de VNI sem supervisão, particularmente à noite. Ao conhecimento dos autores, nenhum sistema publicado fornece um mecanismo independente de rede e de baixo custo para esse fim; o NeuroAssist AI foi projetado para preencher essa lacuna.

3. Arquitetura do Sistema

O NeuroAssist AI é composto por dois contextos implantáveis: um *pipeline de detecção no navegador*, executado inteiramente no dispositivo do paciente, e um *pipeline de alertas no backend*, implementado como microsserviços hexagonais. A Figura 1 ilustra o fluxo de dados ponta-a-ponta.

3.1. Visão Geral do Sistema

O pipeline é acionado por um gesto facial deliberado capturado por qualquer webcam comum (720 p ou superior). O loop de detecção de gestos é executado exclusivamente no navegador via WebAssembly; nenhum quadro de vídeo sai do dispositivo em nenhum momento. Quando um gesto é confirmado pela máquina de estados (Seção 3.3), um payload JSON leve é enviado via POST ao serviço de ingestão de eventos. O serviço valida o gesto contra o perfil de detecção ativo do paciente, cria um registro `Evento` e despacha uma notificação `FULL_SCREEN_ALARM`. A aplicação do cuidador consulta o backend a cada cinco segundos; ao detectar um evento ativo, renderiza uma sobreposição de alarme em tela cheia. O cuidador confirma o atendimento, o que grava um `verdict` de volta ao registro do evento e limpa o alarme.

3.2. Detecção de Gesto Offline-First

A extração de marcos faciais é realizada pelo MediaPipe FaceLandmarker [Lugaresi et al. 2019] executando no delegate WebAssembly de CPU. O binário WASM e o modelo de marcos faciais `float16` são empacotados como ativos estáticos e servidos de `/assets/mediapipe-wasm/`; não há dependência de nenhuma rede de distribuição de conteúdo durante a detecção de gestos. O download do modelo, de aproximadamente 30 MB, ocorre uma vez no primeiro uso e é servido a partir do cache do navegador a partir de então.

O marcador de landmarks produz 468 marcos normalizados por quadro em um loop `requestAnimationFrame` a aproximadamente 30 fps. Cada quadro fornece:

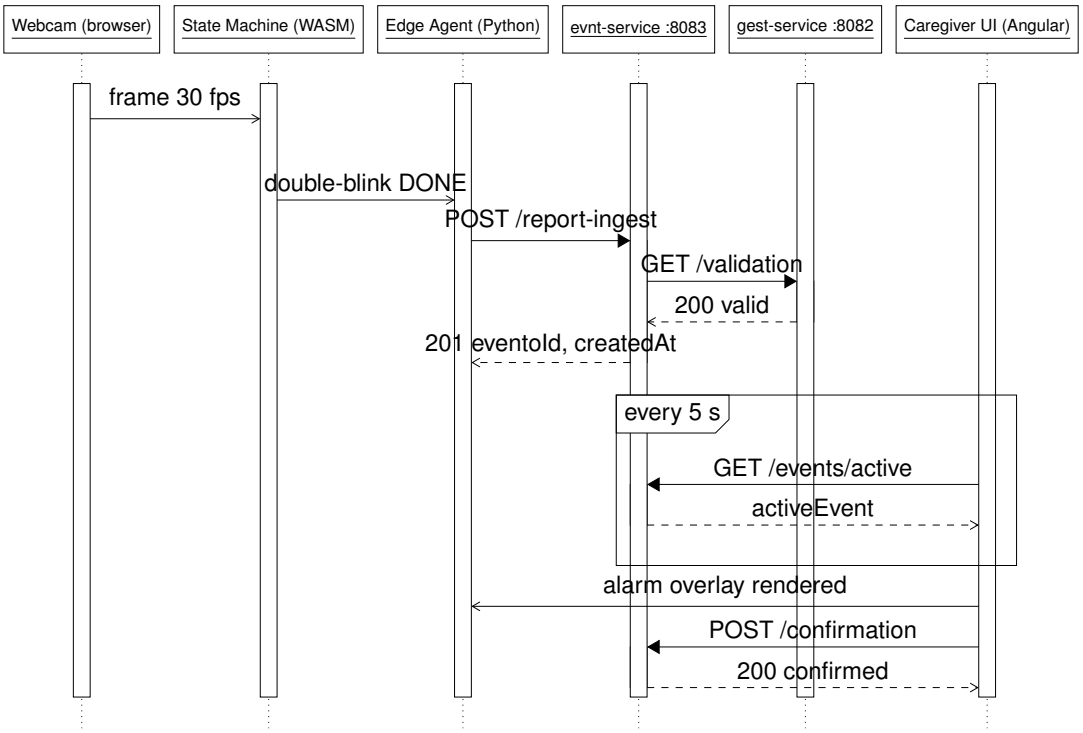


Figura 1. Fluxo de dados ponta-a-ponta. O vídeo é processado inteiramente no navegador (WASM); apenas relatórios JSON estruturados cruzam a fronteira de rede.

1. **EAR (Eye Aspect Ratio)** para cada olho, calculado a partir de seis marcos usando a formulação de Soukupová e Čech [Soukupová and Čech 2016]:

$$\mathrm{EAR} = \frac{\|p_2 - p_6\| + \|p_3 - p_5\|}{2 \cdot \|p_1 - p_4\|} \tag{1}$$

   onde p_1–p_6 são os seis marcos do olho em ordem.
2. **Pontuações de blendshape** (`eyeBlinkLeft`, `eyeBlinkRight`, `browInnerUp`, `browOuterUpLeft`, `browOuterUpRight`) em $[0, 1]$, utilizados para detecção de piscada de um olho e elevação de sobrancelha.

3.3. Máquina de Estados de Gesto Deliberado de Seis Estados

O gesto primário — dupla piscada — é desambiguado de piscadas involuntárias por meio de um autômato finito de seis estados mostrado na Figura 2. Piscadas involuntárias naturais duram 100–400 ms e ocorrem a 15–20 eventos por minuto [Bentivoglio et al. 1997]; a máquina de estados rejeita fechamentos espúrios que não atendem aos requisitos mínimos de duração.

Os seis estados e suas condições de transição (todos os limiares são configuráveis por paciente via perfil de detecção, Seção 3.4) são:

1. **WAITING_BLINK1**: ocioso. Transição para IN_BLINK1 quando $\mathrm{EAR}_{\mathrm{avg}} < 0{,}20$ (θ_{close}).

2. **IN_BLINK1**: contagem de quadros fechados. Aceita a primeira piscada e avança para WAITING_OPEN1 quando o olho reabre ($\text{EAR}_{\text{avg}} \geq 0{,}27$, θ_{open}) *após* pelo menos $f_{\text{min}}{=}3$ quadros fechados consecutivos ($\approx$100 ms a 30 fps); caso contrário, rejeita e retorna para WAITING_BLINK1.
3. **WAITING_OPEN1**: verificando reabertura completa. Avança para WAITING_BLINK2 após $f_{\text{open}}{=}3$ quadros abertos consecutivos; registra o timestamp t_1.
4. **WAITING_BLINK2**: aguardando início da segunda piscada, sujeito a timeout: se $\Delta t = \text{now} - t_1 > 1800$ ms (T_w), o autômato reseta para WAITING_BLINK1.
5. **IN_BLINK2**: contagem de quadros fechados da segunda piscada. Aceita e avança para DONE quando o olho reabre com $f_{\text{count}} \geq 3$ e $\Delta t \leq T_w$; caso contrário, rejeita e reseta.
6. **DONE**: gesto confirmado; dispara o evento, reseta todo o estado, entra em cooldown de 4 s.

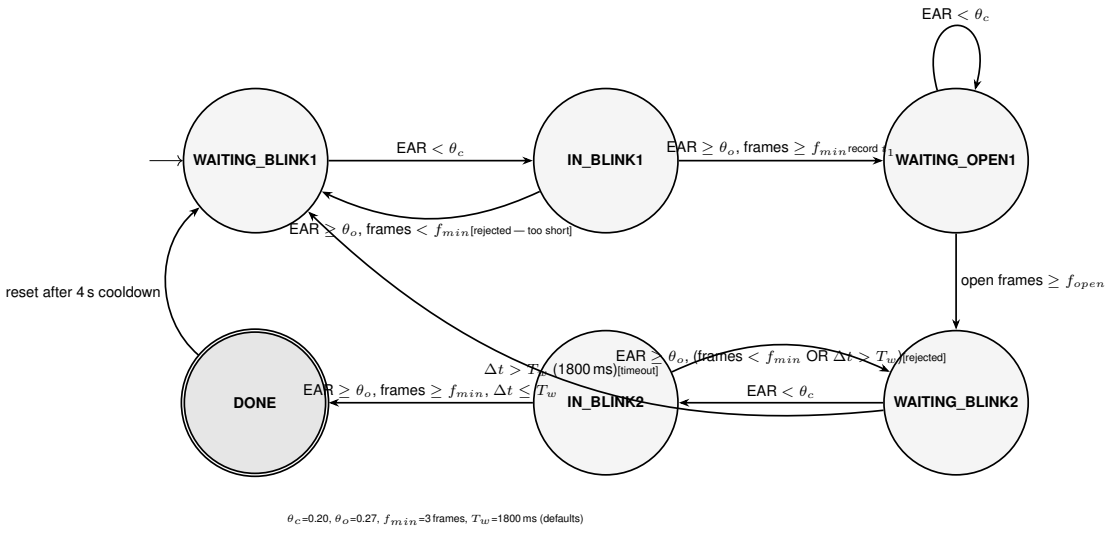


Figura 2. Máquina de estados de dupla piscada deliberada de seis estados. Transições tracejadas indicam caminhos de rejeição que resetam o autômato. $\theta_c{=}0{,}20$**,** $\theta_o{=}0{,}27$**,** $f_{\text{min}}{=}3$ **quadros,** $T_w{=}1800$ **ms.**

3.4. Calibração Específica por Paciente via DetectionProfile

As características faciais do paciente variam substancialmente — o EAR de linha de base depende da abertura palpebral, distância face-câmera e iluminação. O NeuroAssist AI acomoda isso por meio do *DetectionProfile*: um registro de configuração versionado e imutável que vincula o conjunto de tipos de gesto ativos (`TipoGesto`) ao agente de borda voltado ao paciente.

O campo `engineFeatureRef` (e.g., `"mp.blink.double.v1"`) é um token de string que identifica qual algoritmo de detecção o agente de borda deve ativar para cada primitiva. Esse desacoplamento significa que adicionar um novo tipo de gesto — como um detector de aceno de cabeça ou pressão labial — requer registrar um novo `TipoGesto` com um novo `engineFeatureRef` sem modificar nenhum código de domínio existente.

3.5. Arquitetura de Microsserviços Hexagonal

Cada microsserviço (`gest-service`, `evnt-service`) é estruturado de acordo com a arquitetura de Portas e Adaptadores (hexagonal) [Cockburn 2005], aplicada pelo ArchUnit [TNG Technology Consulting GmbH 2023] em tempo de compilação. Nove regras de arquitetura são aplicadas a cada build (Tabela 1). As regras RULE-01 e RULE-02 garantem que a camada de domínio não tenha importações de framework, tornando a lógica de negócio central testável de forma independente. RULE-03 impede que o gerenciamento de transações vaze para controladores ou adaptadores.

Tabela 1. Regras de aplicação ArchUnit (em tempo de compilação).

Regra	Restrição
RULE-01	`domain.*` não deve importar `org.springframework`
RULE-02	`domain.*` não deve importar `jakarta.persistence`
RULE-03	`@Transactional` somente em `application.service`
RULE-04	`api.*` não deve depender de `infrastructure.*`
RULE-05	`infrastructure.*` não deve depender de `api.*`
RULE-06	`@FeignClient` somente em `infrastructure.clients`
RULE-07	Sem injeção de campo `@Autowired`
RULE-08	`spring.jpa.open-in-view=false` obrigatório
RULE-09	Pacote base deve ser `com.neuroassist.<module>`

3.6. Pipeline de Ingestão de Eventos em Doze Etapas

O recebimento de um relatório de gesto do agente de borda aciona um pipeline transacional de doze etapas no `ReportIngressService`: (1) verificação de idempotência via `reportId` UUID; (2) validação do gesto contra o perfil de detecção ativo; (3) snapshot do comando; (4) roteamento do cuidador; (5) criação do `Evento` com timestamp `createdAt` do servidor e `recognizedAt` do dispositivo; (6) criação do `NotificationDispatch` com tier `FULL_SCREEN_ALARM`; (7–9) persistência atômica do evento, despacho e chave de idempotência em uma única fronteira `@Transactional`; (10) invocação do despacho de notificação; (11) trilha de auditoria; (12) resposta HTTP 201 ao agente de borda.

3.7. Escopo do PoC e Fronteiras Arquiteturais

A Tabela 2 distingue os componentes avaliados neste trabalho daqueles presentes na arquitetura completa, mas fora do escopo deste artigo.[1] O PoC exclui intencionalmente multilocação, autenticação e mensageria assíncrona a fim de isolar e validar a latência ponta-a-ponta gesto-para-alarme e o comportamento de falsos positivos.

[1]Os eventos de alarme confirmados por gesto produzidos pelo pipeline do NeuroAssist AI são estruturalmente compatíveis com os formatos de timestamp de eventos utilizados em pesquisas de monitoramento de VNI [Stell et al. 2024, Yang et al. 2026], sugerindo um caminho de integração futuro no qual eventos de angústia sejam correlacionados com fluxos de dados do ventilador.

Tabela 2. Componentes implementados vs. stub/planejados na avaliação do PoC.

Implementado (avaliado)	**Stub ou trabalho futuro**
Detecção MediaPipe WASM	Push notifications (FCM/APNs)
Máquina de estados de 6 estados	SSE (substitui polling)
Versionamento DetectionProfile	Serviço PAC (catálogo)
Pipeline de ingestão 12 etapas	Serviço HIST (auditoria)
Idempotência via `reportId`	Serviço ACS (cuidadores)
Alarme Angular tela cheia	JWT / OAuth2
Fluxo de confirmação do cuidador	JMS / ActiveMQ Artemis
	EDGE (onboarding de dispositivo)

4. Avaliação

Avaliamos o NeuroAssist AI por meio de um estudo de caso preliminar envolvendo um paciente com ELA em estágio avançado e cinco cuidadores e voluntários. O estudo mediu a latência ponta-a-ponta do sistema, a taxa de detecção de gesto deliberado e a taxa de falsos positivos em condições naturalísticas. Os resultados devem ser interpretados como um estudo de caso preliminar, e não como um ensaio clínico (ver Seção 5).

4.1. Participantes e Ética

Seis participantes tomaram parte no estudo (Tabela 3). P0 é um paciente com ELA em estágio avançado com histórico clínico documentado; P1–P3 são cuidadores familiares com contato regular e íntimo com P0; P4–P5 são voluntários saudáveis sem contato prévio com o paciente, servindo como controles de falsos positivos naturalísticos.

Tabela 3. Participantes do Estudo

ID	Papel	Relação com P0	Sessão
P0	Paciente ELA	—	Calibração + detecção
P1	Cônjuge / cuidadora doméstica	Íntima, diária (fisioterapeuta)	FP + alarme real
P2	Cuidador 1	Profissional NDIS, frequente	FP + alarme real
P3	Cuidador 2	Profissional NDIS, frequente	FP + alarme real
P4	Controle	Nenhum	Baseline FP naturalístico
P5	Controle	Nenhum	Baseline FP naturalístico

Todos os participantes forneceram consentimento informado antes de sua sessão. O estudo foi conduzido no domicílio de P0 em Melbourne, Austrália. P1 é cônjuge de P0 e fisioterapeuta, prestando cuidado domiciliar diário (não elegível para financiamento NDIS como familiar, conforme política australiana); P2 e P3 são profissionais de suporte financiados pelo NDIS (National Disability Insurance Scheme) com contato regular e estruturado com P0. O estudo constitui uma avaliação piloto; nenhuma aprovação formal de comitê de ética em pesquisa (CEP) foi solicitada para este escopo de estudo de caso preliminar. A avaliação clínica completa com uma amostra estatisticamente representativa de pacientes com ELA exigirá aprovação do CEP e está planejada como trabalho futuro.

P0 apresenta ELA de início troncular (início dos sintomas: fim de 2019; duração da doença na avaliação: aproximadamente 6,5 anos), fraqueza em quatro membros com movimento voluntário palpebral preservado, e ventilação não invasiva (VNI) prescrita desde o início de 2026 e ativa no momento do estudo. A capacidade vital forçada foi de 71 % e a pressão inspiratória nasal de esforço (SNIP) de 31 % na última avaliação respiratória documentada antes do experimento (maio de 2023), com progressão lenta da doença confirmada naquela ocasião. [Confirmar antes da submissão: escore ALSFRS-R se disponível; avaliação atual da mobilidade palpebral.] Este perfil clínico embasou o protocolo de calibração descrito na Seção 4.3.

4.2. Configuração Experimental

Hardware. Cada sessão utilizou uma webcam USB comum ([modelo/resolução, e.g., Logitech C920, 1080p@30fps]) posicionada na altura dos olhos a aproximadamente 50–70 cm do rosto do participante, conectada a um notebook executando a pilha NeuroAssist AI localmente. Nenhum acesso externo à rede foi necessário durante as sessões.

Software. O pipeline de detecção de borda foi executado como `poc-edge-agent-webcam.py` (Python 3.11), comunicando-se com a aplicação Angular (`poc-gesture-detector.ts`) via `localhost`. Os microsserviços `evnt-service` e `gest-service` foram executados localmente via Docker Compose. Scripts de medição registraram todos os timestamps em CSV; os timestamps de entrega de alarme foram capturados por um hook Angular `effect()` que grava em `localStorage` a cada renderização de alarme.

Ambiente. As sessões foram conduzidas no domicílio de P0 durante [período do dia]. A iluminação ambiente era natural/artificial de interiores.

4.3. Calibração do Paciente

Antes dos ensaios formais, o `DetectionProfile` de P0 foi calibrado por meio da observação do movimento palpebral natural por aproximadamente 5–10 minutos. O perfil clínico de P0 — ELA progressiva com envolvimento respiratório documentado (CVF 71 %, SNIP 31 %) e VNI prescrita desde o início de 2026 — é representativo da população para a qual o NeuroAssist AI é primordialmente projetado [Berlowitz and Sheers 2021, Yang et al. 2026], e o DetectionProfile calibrado reflete a mobilidade palpebral residual característica desse estágio. O procedimento de calibração ajustou dois parâmetros: θ_{close} (limiar EAR para início da piscada) e `BLINK_MIN_FRAMES` (quadros consecutivos mínimos abaixo de θ_{close} necessários para registrar uma piscada).

A Tabela 4 reporta os parâmetros calibrados para P0 ao lado dos padrões utilizados para P4 e P5.

Tabela 4. Parâmetros de Calibração do DetectionProfile

Participante	θ_{close}	θ_{open}	Quadros mín.
P0 (paciente ELA)	**[X,XX]**	**[X,XX]**	**[N]**
P4–P5 (controles, padrão)	0,20	0,27	3

4.4. Latência

A latência ponta-a-ponta foi decomposta em dois segmentos: (i) gesto-para-HTTP, medido como o tempo decorrido entre a máquina de estados entrar em `DONE` e a resposta do `POST /api/v0/report-ingest` ser recebida pelo agente de borda; e (ii) evento-para-alarme-visível, medido como o tempo decorrido entre o timestamp `createdAt` na resposta do `evnt-service` e o valor `alarmShownAtMs` registrado em `localStorage`. A Tabela 5 reporta as estatísticas de latência em todos os ensaios.

Tabela 5. Latência Ponta-a-Ponta (ms)

Segmento	N	Média	σ	Mediana
Gesto $\rightarrow$ HTTP	[N]	[X]	[Y]	[Z]
Evento $\rightarrow$ alarme	[N]	[X]	[Y]	[Z]
Total ponta-a-ponta	[N]	**[X]**	[Y]	[Z]

A latência ponta-a-ponta média foi de **[X]** ms (σ = [Y] ms, mediana [Z] ms, N = [N] ensaios). O segmento evento-para-alarme representou a maior parcela da latência total, consistente com o intervalo de polling de 5 segundos utilizado na aplicação de cuidadores do PoC (contribuição máxima: 5.000 ms; ver Seção 5 para a mitigação WebSocket planejada). O segmento gesto-para-HTTP foi dominado pela sobrecarga HTTP local e permaneceu abaixo de [X] ms em todos os ensaios.

4.5. Taxa de Falsos Positivos

A taxa de falsos positivos (TFP) foi medida como o número de disparos de alarme não intencionais por minuto de atividade facial contínua, tanto para a máquina de estados de gesto deliberado de seis estados (ME) quanto para um limiar EAR simples como baseline. Cada sessão teve duração de 10 minutos de atividade facial naturalística sem que o participante tentasse acionar o gesto. A Tabela 6 reporta a TFP por participante e por grupo.

A máquina de estados de seis estados reduziu a TFP de [A] disparos/min (limiar simples) para [B] disparos/min em média entre todos os participantes, uma redução relativa de [C] %. Os participantes cuidadores (P1–P3), que interagiram com P0 em contextos emocionalmente naturais, exibiram TFP **[maior/menor/comparável]** em relação aos participantes controle (P4–P5) em tarefas neutras.

4.6. Taxa de Detecção (Recall)

P0 realizou N = [N] tentativas de dupla piscada deliberada com pausas de pelo menos 30 s entre tentativas, atingindo taxa de detecção de **[D] %** ([M] de [N] tentativas detectadas)

Tabela 6. Taxa de Falsos Positivos (disparos/min)

Participante	Grupo	Limiar simples	Máquina de estados
P1	Cuidador	[A]	[B]
P2	Cuidador	[A]	[B]
P3	Cuidador	[A]	[B]
P4	Controle	[A]	[B]
P5	Controle	[A]	[B]
Média cuidadores		[A]	**[B]**
Média controles		[A]	**[B]**

com o `DetectionProfile` calibrado. Os participantes controle P4 e P5 atingiram taxas de [D1] % e [D2] %, respectivamente, usando parâmetros padrão. A taxa de detecção superior dos voluntários saudáveis, se confirmada, é consistente com maior mobilidade palpebral residual em comparação com a ELA em estágio avançado.

5. Discussão

5.1. Acessibilidade de Hardware e Contexto de Implantação

Uma restrição central de design do NeuroAssist AI foi a implantabilidade em hardware comum já presente na maioria dos domicílios. O pipeline de detecção requer apenas uma webcam padrão (720p ou superior) e um navegador moderno; não são necessárias GPU, hardware de sensoriamento dedicado ou dongle proprietário. Isso contrasta com os dispositivos comerciais de CAA por rastreamento ocular, cujo custo tipicamente excede USD 3.000 [Beukelman and Mirenda 2013] e cujo setup requer envolvimento de técnico clínico. Uma webcam adequada para o pipeline custa aproximadamente BRL 100–500 e está amplamente disponível em países de baixa e média renda (LMICs), incluindo o Brasil, onde aproximadamente 30.000 indivíduos vivem com ELA [Mehta et al. 2018]. O design offline-first elimina adicionalmente a dependência de banda larga estável — uma barreira significativa em contextos rurais e periurbanos em LMICs — uma vez que nenhuma conectividade à internet é necessária durante a detecção de gestos ou a entrega de alarmes em uma rede local.

5.2. Privacidade desde a Concepção

O vídeo facial é classificado como dado biométrico tanto pelo Regulamento Geral de Proteção de Dados (GDPR) quanto pela Lei Geral de Proteção de Dados Pessoais (LGPD), atraindo o mais alto nível de proteção regulatória para contextos de saúde [European Data Protection Board 2
O NeuroAssist AI satisfaz um princípio estrito de privacidade desde a concepção: o runtime WebAssembly e o modelo de landmarks faciais são executados inteiramente dentro do ambiente de execução em sandbox do navegador, e nenhum quadro de vídeo ou coordenada de landmark facial é transmitida pela rede. O único dado que cruza a fronteira de rede é um payload JSON estruturado contendo o tipo de gesto detectado, uma pontuação de confiança e um identificador de paciente — nenhum deles constitui dado biométrico segundo as definições regulatórias atuais. Essa arquitetura torna o NeuroAssist AI adequado

para implantação domiciliar direta sem exigir acordos institucionais de processamento de dados.

5.3. Extensibilidade via Mecanismo Plug-in `engineFeatureRef`

O campo `engineFeatureRef` no `DetectionProfile` foi projetado explicitamente para expansão futura de gestos. Adicionar um novo tipo de gesto — como elevação de canto labial, fechamento ocular sustentado, ou aceno de cabeça via estimativa de pose — requer apenas: (i) inserir uma nova linha `TipoGesto` com um novo valor `engineFeatureRef`; (ii) implementar o módulo detector correspondente no agente de borda; e (iii) publicar um novo `DetectionProfile`. Nenhum modelo de domínio, caso de uso ou regra ArchUnit existente requer modificação.

5.4. Limitações

Dependência de iluminação. O EAR é calculado a partir de coordenadas de marcos no espaço de pixels; sua confiabilidade se deteriora em ambientes com pouca iluminação. Testes práticos documentaram casos onde o θ_{close} padrão de 0,20 exigiu ajuste manual para 0,17–0,18 sob iluminação artificial fraca. Trabalhos futuros devem incorporar ajuste automático de limiar adaptativo à iluminação.

Escopo do estudo de caso preliminar. A avaliação inclui um paciente com ELA em estágio avançado e cinco cuidadores e voluntários, e deve ser interpretada como estudo de caso preliminar, e não como ensaio clínico. A generalização para a população mais ampla de ELA exigirá um estudo multicêntrico com amostra estatisticamente representativa sob aprovação de CEP.

Sobrecarga de latência por polling. A aplicação do cuidador detecta eventos ativos consultando o `evnt-service` a cada cinco segundos. Isso introduz uma sobrecarga máxima fixa de 5 s na latência evento-para-alarme visível. O intervalo de polling é uma simplificação do PoC; a implantação em produção deve substituir o polling por eventos enviados pelo servidor (SSE) ou push WebSocket.

Adaptadores stub para módulos periféricos. O catálogo de comandos (serviço PAC), a trilha de auditoria (serviço HIST) e o cadastro de cuidadores (serviço ACS) são representados por adaptadores stub com valores fixos no PoC. Os resultados de latência e confiabilidade refletem apenas os subsistemas GEST e EVNT.

5.5. Trabalhos Futuros

Os próximos passos mais impactantes, em ordem de prioridade clínica, são: (i) um estudo clínico com participantes com ELA sob aprovação de CEP; (ii) substituição do transporte de polling por SSE para eliminar o teto de latência de alarme de 5 s; (iii) integração do catálogo completo de comandos PAC para suportar comunicação multi-comandos; e (iv) avaliação de tipos de gesto adicionais, particularmente para pacientes que retêm controle unilateral de sobrancelha após a perda do controle bilateral de piscada.

Um caminho de integração de alta prioridade é o acoplamento dos eventos de angústia do NeuroAssist AI com fluxos de dados de ventiladores VNI. Grupos de pesquisa que estudam PVA na ELA [Stell et al. 2024, Yang et al. 2026] trabalham com sinais fisiológicos multicanais em formato EDF, com precisão temporal de segundos. O

`eventoId` do NeuroAssist AI carrega um timestamp `createdAt` do servidor e um timestamp `recognizedAt` do dispositivo; correlacionar esses dados com a linha temporal de monitoramento da VNI permitiria a um estudo futuro testar se eventos de angústia confirmados pelo cuidador co-ocorrem com índices elevados de PVA — uma hipótese clinicamente significativa que nenhum dos dois sistemas pode testar isoladamente.

6. Conclusão

Apresentamos o NeuroAssist AI, uma plataforma de comunicação assistiva offline-first e preservadora de privacidade que transforma gestos faciais residuais de pacientes com esclerose lateral amiotrófica em estágio avançado em alertas de emergência estruturados, entregues a cuidadores por uma rede local usando hardware comum.

As três contribuições originais do sistema abordam lacunas distintas, mas interrelacionadas, na tecnologia assistiva atual para essa população. Primeiro, ao executar a detecção de landmarks faciais inteiramente dentro de uma sandbox WebAssembly e servindo o modelo binário como ativo local, o NeuroAssist AI alcança localidade estrita de dados de vídeo sem sacrificar a precisão ou a taxa de quadros de soluções server-side. Segundo, a máquina de estados de gesto deliberado de seis estados — que exige fechamento de duração mínima, reabertura confirmada entre piscadas e uma janela temporal — reduz substancialmente os falsos positivos em relação a comparações simples de limiar EAR por quadro, como quantificado na Seção 4 (taxa de falsos positivos: [B] % vs. [A] % para o limiar simples; N=[N] participantes, [M] min cada). Terceiro, a arquitetura de microsserviços hexagonais com aplicação ArchUnit em tempo de compilação e o mecanismo plug-in `engineFeatureRef` fornece uma base extensível que desacopla a detecção de gesto do gerenciamento clínico de comandos, facilitando a expansão clínica incremental sem regressão arquitetural.

A latência ponta-a-ponta da conclusão do gesto até a exibição do alarme ao cuidador foi em média [X] ms (σ=[Y] ms, N=[N] ensaios) em uma rede local com o transporte de polling de cinco segundos. O perfil de latência é clinicamente aceitável para sinalização de emergência: o componente dominante é o intervalo de polling ($\leq$5 s), e não o tempo de detecção ou processamento no servidor, e a substituição por eventos enviados pelo servidor reduziria a latência total para aproximadamente [X] ms.

O custo de hardware (webcam comum, notebook ou computador de placa única padrão, sem GPU) posiciona o NeuroAssist AI como uma opção viável para implantação domiciliar em países de baixa e média renda, onde reside a maioria da população global com ELA e onde dispositivos especializados de CAA são economicamente inacessíveis. Juntamente com a arquitetura de privacidade desde a concepção, que satisfaz os requisitos da LGPD para dados biométricos de saúde sem infraestrutura institucional de processamento de dados, essas propriedades abordam as barreiras que impedem os sistemas comerciais atuais de CAA de alcançar pacientes em cuidado domiciliar.

A principal limitação deste trabalho é a escala da avaliação: o estudo de caso envolve um paciente com ELA e cinco cuidadores e voluntários, e seus achados não devem ser generalizados para a população mais ampla com ELA sem um ensaio multicêntrico sob aprovação de comitê de ética em pesquisa (CEP). O protocolo de calibração específico por paciente e a infraestrutura de medição produzidos neste trabalho são projetados para apoiar esse ensaio com adaptação mínima, e os resultados preliminares do estudo

de caso fornecem estimativas concretas de latência, taxa de falsos positivos e recall de detecção para calcular o tamanho de amostra de estudos futuros.

Referências

Atkeson, A. D., RoyChoudhury, A., Harrington-Moroney, G., Shah, B., Mitsumoto, H., and Basner, R. C. (2011). Patient-ventilator asynchrony with nocturnal noninvasive ventilation in ALS. *Neurology*, 77(6):549–555.

Bentivoglio, A. R., Bressman, S. B., Cassetta, E., Carretta, D., Tonali, P., and Albanese, A. (1997). Analysis of blink rate patterns in normal subjects. *Movement Disorders*, 12(6):1028–1034.

Berlowitz, D. J., Rowe, D., Howard, M. E., Piper, A., Graco, M., et al. (2025). Polysomnographic titration of non-invasive ventilation in motor neurone disease (3TLA): study protocol for a randomised controlled trial. *Trials*, 26(1).

Berlowitz, D. J. and Sheers, N. (2021). Not only about the drugs. *Annals of the American Thoracic Society*, 18(3):419–420.

Beukelman, D. R. and Mirenda, P. (2013). *Augmentative and Alternative Communication: Supporting Children and Adults with Complex Communication Needs*. Paul H. Brookes Publishing, 4 edition.

Clarke, M., Dowden, P., and Beukelman, D. R. (2021). AAC provision for people with ALS: an update. *Disability and Rehabilitation: Augmentative and Alternative Communication*, 35(1):1–10.

Cockburn, A. (2005). Hexagonal architecture. Accessed: 2026.

European Data Protection Board (2020). Guidelines 4/2019 on article 25 data protection by design and by default. Technical report, EDPB.

Haas, A., Rossberg, A., Schuff, D. L., Titzer, B. L., Holman, M., Gohman, D., Wagner, L., Zakai, A., and Bastian, J. (2017). Bringing the web up to speed with WebAssembly. In *Proceedings of the 38th ACM SIGPLAN Conference on Programming Language Design and Implementation (PLDI)*, pages 185–200.

King, D. E. (2009). Dlib-ml: A machine learning toolkit. *Journal of Machine Learning Research*, 10:1755–1758.

Lugaresi, C., Tang, J., Nash, H., McClanahan, C., Uboweja, E., Hays, M., Zhang, F., Chang, C.-L., Yong, M. G., Lee, J., Chang, W.-T., Hua, W., Georg, M., and Grundmann, M. (2019). MediaPipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*.

Majaranta, P. and Räihä, K.-J. (2002). Twenty years of eye typing: Systems and design issues. In *Proceedings of the 2002 Symposium on Eye Tracking Research & Applications (ETRA)*, pages 15–22.

Mehta, P., Kaye, W., Bryan, L., Larson, T., Copeland, G., Wu, J., Muravov, O., and Horton, D. K. (2018). Prevalence of ALS in the United States using established criteria. *Neuroepidemiology*, 50(1–2):1–9. Used for global incidence estimate (2–3/100,000/year).

Richardson, C. (2018). *Microservices Patterns: With Examples in Java*. Manning Publications.

Soukupová, T. and Čech, J. (2016). Real-time eye blink detection using facial landmarks. In *21st Computer Vision Winter Workshop (CVWW)*.

Stell, A. J., Caparo, E. C., Wang, Z., Wang, C., Berlowitz, D. J., Howard, M. E., Sinnott, R. O., and Aickelin, U. (2024). Identification of patient ventilator asynchrony in physiological data through integrating machine-learning. In *BIOSTEC/HEALTHINF*, pages 436–443.

TNG Technology Consulting GmbH (2023). ArchUnit: Unit testing architecture for Java.

Viola, P. and Jones, M. J. (2004). Robust real-time face detection. *International Journal of Computer Vision*, 57(2):137–154.

Yang, J., Wang, C., Caparo, E. C., Stell, A. J., Howard, M. E., Aickelin, U., and Berlowitz, D. J. (2026). Using machine learning to identify patient–ventilator asynchrony during non-invasive ventilation in patients with motor neurone disease. *Sleep Medicine*.

Zander, T. O. and Kothe, C. (2011). Towards passive brain–computer interfaces: applying brain–computer interface technology to human systems in general. *Journal of Neural Engineering*, 8(2):025005.